

pipeline_comparison.py - IFMG Formiga 2026

Comparação de Pipelines de Aprendizagem de Máquina

Previsão de Evasão Estudantil no KNIME

```
from knime import RandomForest, PCA
```

```
dataset = "student_dropout_10k.csv"
```

```
question = "O pré-processamento sempre melhora os resultados?"
```

Autores: Flávio, Luisa, Maria Luzia, Yasmin

Disciplina: Inteligência Artificial

```
$ cat problema.md
```

problema.md

A Questão Central

Dados brutos frequentemente apresentam:

> Valores ausentes

> Outliers

> Alta dimensionalidade

Pergunta: "O tratamento sempre melhora o modelo?"

```
$ diff pipeline_a pipeline_b
```

■ Pipeline A: Sem Tratamento

- > Dados brutos direto no modelo
- > 18 variáveis originais mantidas
- > 5% de missing values no dataset
- > Random Forest lida internamente
- > *Vencedor: 79.7% acurácia*

■ Pipeline B: Com Tratamento


- > Missing values → média da coluna
- > 1.098 outliers tratados (IQR)
- > Normalização Z-score aplicada
- > PCA: 17 → 5 variáveis (-70%)
- > *Perdeu informação discriminativa*

```
$ classifier = "Random Forest" # Mesmo para ambos  
$ train_split = 70% | test_split = 30%
```




```
$ open pipeline_a.knwf
```

Pipeline A: Sem Tratamento de Dados



\$ open pipeline_b.knwf


Pipeline B: Com Tratamento Completo



Missing Value → Outliers → Normalizer → PCA → Random Forest → Scorer

```
$ open pipeline_b.knwf
```

Pipeline B: Com Tratamento Completo



Missing Value → Outliers → Normalizer → PCA → Random Forest → Scorer


```
$ python compare_results.py
```

```
results_comparison.txt


# Comparação de Métricas

Métrica                Sem Trat.                Com Trat.
Acurácia                79.7%                    78.2%
Recall (Evadiu)         60.7%                    55.2%
Precisão (Evadiu)       39.1%                    41.2%
F1-Score (Evadiu)       47.6%                    47.2%

>>> winner = "Pipeline SEM Tratamento"
```



```
$ plot comparison_chart.png
```



Recall
% de evasões reais detectadas

Precision
% de previsões corretas de evasão

F-measure
Equilíbrio entre Recall e Precision

Accuracy
% total de acertos do modelo

> Verde vence em 3 de 4 métricas

Verde = Sem Tratamento | Azul = Com Tratamento


```
$ explain --why-no-improvement
```

analysis.log

[1] Random Forest é robusto

Lida internamente com missing values e outliers

[2] PCA descartou informação útil

17 → 5 variáveis pode eliminar padrões discriminativos

[3] Dados já eram de boa qualidade

Apenas 5% de missing values - tratamento pouco impactante

```
$ return conclusion
```

```
conclusion.py - Resultado Final

def resposta():
    """
    O tratamento dos dados contribuiu para
    melhorar o desempenho do classificador?
    """
    return False # NÃO melhorou!

>>> "Pipeline SEM tratamento: 79.7% acurácia"
>>> "Pipeline COM tratamento: 78.2% acurácia"
>>> diferenca = +1.5% # a favor dos dados brutos
```

