

Alunos: Flávio Reis, Luisa Caetano, Maria Luzia de Moura Sanches, Yasmim Stefane Faria

**INTELIGENCIA
ARTIFICIAL**

PIPELINE DE TRATAMENTO DE DADOS

BASE DE DADOS



Student Dropout Prediction Dataset

- **Fonte:** Kaggle
- **Registros:** 10.000 estudantes
- **Atributos:** 19 variáveis
- **Dados faltantes:** ~5% dos registros
- **Outliers:** Presentes em variáveis numéricas
- **Taxa de evasão:** 23,5%

Problema abordado:

- Evasão escolar é um desafio crítico em instituições educacionais
- Identificar alunos em risco permite intervenções preventivas
- Dataset simula cenários educacionais reais

VARIÁVEL ALVO



Dropout (Evasão)

- **Tipo:** Binária (0 ou 1)
- **Distribuição:**
 - **0 (Permaneceu):** 7.650 estudantes (76,5%)
 - **1 (Evadiu):** 2.350 estudantes (23,5%)

Desbalanceamento:

- Dataset levemente desbalanceado
- Mais estudantes permanecem do que evadem
- Importante considerar em algoritmos de classificação

IDENTIFICAÇÃO DOS VALORES FALTANTES

Ferramenta utilizada: Nó Statistics do KNIME

COLUNA	VALORES AUSENTES	PERCENTUAL
<i>Family_Income</i>	500	5%
Study_Hours_per_Day	500	5%
<i>Stress_Index</i>	500	5%
Total	1.500	0,79%

Estratégia de tratamento:

- *Imputação pela média;*
- *Os valores faltantes foram substituídos pela média da coluna;*
- *Como faltam poucos dados, dá para substituir esses valores sem mudar muito o comportamento original dos dados.*

TRATAMENTO DE OUTLIERS

Tratamento de Outliers (IQR):

- **Método:** IQR (Intervalo Interquartil) calculado como $IQR = Q3 - Q1$.
- **Limites de detecção:**
 - **Inferior:** $Q1 - 1,5 \times IQR$
 - **Superior:** $Q3 + 1,5 \times IQR$
- Valores fora desses limites são considerados outliers.

Colunas excluídas:

- **Student_ID:** identificador
- **GPA / Semester_GPA / CGPA:** escala fixa (0-4)
- **Dropout:** variável binária (0 ou 1)

Estratégia de tratamento:

- **Winsorização:** substituição de valores extremos pelo limite mais próximo.
 - Preserva dados
 - Pode suavizar extremos reais

COLUMNAS ANALISADAS

COLUMNAS	OUTLIERS ENCONTRADOS
<i>Family_Income</i>	683
<i>Study_Hours_per_Day</i>	138
<i>Stress_Index</i>	137
<i>Attendance_Rate</i>	57
<i>Age</i>	33
<i>Assignment_Delay_Days</i>	25
<i>Travel_Time_Minutes</i>	25
Total	1.098

COLUMNAS EXCLUÍDAS	
COLUMNAS	MOTIVO DA EXCLUSÃO
<i>Student_ID</i>	Identificador, não é variável
GPA, Semester_GPA, CGPA	Escala fixa (0-4), não tem outliers
<i>Dropout</i>	Variável alvo binária (0 ou 1)

ESTRATÉGIAS POSSÍVEIS

TÉCNICA	DESCRIÇÃO	PRÓS	CONTRAS
<i>Remoção</i>	<i>Excluir registros com outliers</i>	Simples de aplicar	Perda de dados
Winsorização	Substituir pelo limite mais próximo	Preserva todos os dados	Pode suavizar extremos reais
<i>Transformação</i>	<i>Aplicar log, raiz quadrada</i>	Reduz impacto dos extremos	Dificulta interpretação
Manter	Não tratar outliers	Preserva dados originais	Pode distorcer modelos

REDUÇÃO DE DIMENSIONALIDADE

PCA (Principal Component Analysis)

Análise: Antes

O dataset é composto por 19 atributos que capturam diferentes aspectos da vida do estudante. Com exatamente 10.000 registros

Atributos numéricos (entram no PCA): Idade, Renda Familiar, Horas de Estudo por Dia, Taxa de Presença, Dias de Atraso em Tarefas, Tempo de Deslocamento (minutos), Índice de Estresse, GPA, GPA do Semestre, CGPA

Atributos categóricos (convertidos): Gênero, Acesso à Internet, Trabalho de Meio Período, Bolsa de Estudos, Semestre, Departamento, Escolaridade dos Pais

Identificador (excluído): ID do Estudante

Variável alvo (excluída): Evasão Escolar

Variável alvo (excluída): Dropout

SAÍDA DO PCA

Rows: 10000 | Columns: 7

Table

Statistics

#

RowID

Student_ID

.00

Number (Float)

Dropout

.00

Number (Float)

PCA dimension 0

.00

Number (Float)

PCA dimension 1

.00

Number (Float)

PCA dimension 2

.00

Number (Float)

PCA dimension 3

.00

Number (Float)

PCA dimension 4

.00


Number (Float)

1	Row0	1	0	-2.162	-0.129	-0.152	0.601	-0.724
2	Row1	2	1	-2.066	0.786	0.221	-0.824	1.104
3	Row2	3	0	-1.444	0.127	1.261	-0.18	0.634
4	Row3	4	1	-0.819	-0.227	-0.239	0.478	0.462
5	Row4	5	0	-2.157	1.294	-0.781	-0.333	-0.413
6	Row5	6	0	0.622	0.123	-0.589	-0.452	0.891
7	Row6	7	0	-3.243	-0.984	0.512	0.287	-0.513

Análise:Depois

- transformadas em 5 componentes principais (PCA dimension 0 a 4)
- representa uma combinação linear das variáveis originais
- 0 concentra a maior parte da variância do conjunto de dados
- valores positivos indicam estudantes acima da média do grupo, enquanto os valores negativos indicam estudantes abaixo da média
- pipeline teve uma redução de 67%

IMPLEMENTAÇÃO NO KNIME



FLUXO DE DADOS

ETAPA	ENTRADA	SAÍDA
<i>Importação</i>	CSV bruto	10.000 × 19
Missing Value	1.500 ausentes	0 ausentes
<i>Outliers</i>	1.098 extremos	0 extremos
PCA	17 variáveis	5 componentes
Final	10.000 × 19	10.000 × 7

CONCLUSÃO

O pipeline de tratamento de dados desenvolvido neste trabalho demonstrou-se eficaz na preparação do dataset Student Dropout Prediction para algoritmos de aprendizado de máquina.

Foram tratados 1.500 valores faltantes através da imputação pela média, 1.098 outliers corrigidos por winsorização utilizando o método IQR com fator $k=1,5$, e a dimensionalidade foi reduzida de 17 para 5 variáveis através do PCA, representando uma compressão de 70,6%.

O diferencial do pipeline foi a **preservação total dos 10.000 registros originais**, sem exclusão de nenhuma observação. O dataset final contém 7 colunas (Student_ID, Dropout e 5 componentes principais), estando limpo, normalizado e livre de inconsistências.