

**INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE MINAS
GERAIS – CAMPUS FORMIGA**

INTELIGÊNCIA ARTIFICIAL

**FLÁVIO ALEXANDRE SILVA REIS
LUISA CAETANO ARAÚJO
MARIA LUZIA DE MOURA SANCHES
YASMIN STEFANE FARIA**

**PIPELINE DE TRATAMENTO DE DADOS PARA APRENDIZADO DE
MÁQUINA
PREVISÃO DE EVASÃO ESTUDANTIL**

FORMIGA

2026

1. INTRODUÇÃO

A qualidade dos dados é um fator determinante para o sucesso de projetos de Aprendizado de Máquina. Dados brutos frequentemente apresentam inconsistências, valores ausentes e anomalias que podem comprometer significativamente o desempenho dos modelos preditivos. Nesse contexto, o pré-processamento de dados torna-se uma etapa fundamental no pipeline de desenvolvimento de soluções de Inteligência Artificial.

O presente trabalho tem como objetivo aplicar técnicas de tratamento de dados em uma base real, construindo um pipeline de pré-processamento utilizando a ferramenta KNIME Analytics Platform. A base de dados escolhida contém informações de 10.000 estudantes e visa prever a evasão escolar (dropout) a partir de variáveis demográficas, socioeconômicas e acadêmicas.

O pipeline desenvolvido contempla três etapas essenciais de tratamento:

- **Tratamento de Dados Faltantes:** identificação e imputação de valores ausentes;
- **Tratamento de Outliers:** detecção e tratamento de valores extremos;
- **Redução de Dimensionalidade:** aplicação de técnicas para reduzir o número de variáveis.

2. BASE DE DADOS

2.1 IDENTIFICAÇÃO

A base de dados utilizada neste trabalho foi obtida no repositório Kaggle, uma das maiores plataformas de compartilhamento de datasets para ciência de dados e aprendizado de máquina.

O dataset selecionado, denominado Student Dropout Prediction Dataset, contém registros de 10.000 estudantes universitários caracterizados por 19 atributos distintos. A base foi projetada para simular cenários reais de instituições de ensino superior, incorporando características como valores faltantes em aproximadamente 5% dos registros e a presença de outliers em variáveis como renda familiar.

Item	Descrição
Nome	Student Dropout Prediction Dataset
Fonte	Kaggle
Link	https://www.kaggle.com/datasets/meharshanali/student-dropout-prediction-dataset
Número de Registros	10.000
Número de Atributos	19

2.2 DESCRIÇÃO DO PROBLEMA

A evasão escolar representa um dos maiores desafios enfrentados por instituições de ensino em todo o mundo. Quando um estudante abandona seu curso, há perdas significativas tanto para o indivíduo, que interrompe sua formação, quanto para a instituição, que perde recursos investidos e compromete seus indicadores de qualidade.

Nesse contexto, a capacidade de identificar precocemente estudantes com risco de abandono torna-se uma ferramenta valiosa. Com modelos preditivos bem treinados, gestores educacionais podem implementar intervenções direcionadas, como tutoria, apoio psicológico ou auxílio financeiro, antes que o estudante efetivamente abandone o curso.

O dataset selecionado foi construído exatamente para esse propósito: treinar modelos capazes de prever se um aluno irá evadir ($\text{dropout} = 1$) ou permanecer na instituição ($\text{dropout} = 0$). A taxa de evasão presente na base é de aproximadamente 23,5%, ou seja, de cada 100 estudantes, cerca de 24 abandonaram seus cursos.

2.3 ESTRUTURA DE DADOS

O dataset é composto por 19 atributos que capturam diferentes aspectos da vida do estudante. Para facilitar a compreensão, organizamos essas variáveis em quatro categorias: dados demográficos, socioeconômicos, acadêmicos e comportamentais.

1. Dados Demográficos

Os dados demográficos identificam características básicas do estudante. O atributo `Student_ID` funciona como identificador único, permitindo distinguir cada registro. A variável `Age` representa a idade do estudante em anos, variando de 17 a 29 anos na base. Já `Gender` indica o sexo do estudante, podendo assumir os valores "Male" (masculino) ou "Female" (feminino).

2. Dados Socioeconômicos

As variáveis socioeconômicas capturam o contexto financeiro e familiar do estudante, fatores frequentemente associados ao risco de evasão.

A variável `Family_Income` representa a renda mensal familiar em unidades monetárias. Esta variável apresenta grande variação, com valores entre 25.000 a 316.000 (unidade monetária não especificada no dataset original), indicando a presença de outliers que precisarão ser tratados.

O atributo `Parental_Education` indica o nível de escolaridade mais alto atingido pelos pais, podendo ser "High School" (ensino médio), "Bachelor" (graduação), "Master" (mestrado) ou "None" (sem escolaridade formal). Este último valor foi posteriormente padronizado para "No_Education" durante o tratamento de dados. Estudos mostram que o nível educacional dos pais influencia diretamente o desempenho e permanência dos filhos no ensino superior.

Três variáveis binárias complementam este grupo: `Internet_Access` indica se o estudante possui acesso à internet em casa; `Part_Time_Job` revela se o estudante trabalha em tempo parcial, o que

pode afetar seu tempo disponível para estudos; e Scholarship indica se o estudante é beneficiário de bolsa de estudos.

3. Dados Acadêmicos

O desempenho acadêmico é naturalmente um dos principais indicadores de risco de evasão. O dataset inclui três métricas de desempenho complementares: GPA (Grade Point Average) representa a média geral de notas;

Semester_GPA captura o desempenho no semestre atual; e CGPA (Cumulative GPA) indica a média acumulada ao longo do curso. Todas variam de 0 a 4 pontos.

A variável Semester indica em qual ano do curso o estudante se encontra, variando de "Year 1" a "Year 4". O atributo Department identifica o departamento do curso, incluindo categorias como "Science", "Arts", "Business", "CS" (Ciência da Computação) e "Engineering".

Por fim, Attendance_Rate mede a taxa de presença do estudante em porcentagem, variando de 0% a 100%.

4. Dados Comportamentais

As variáveis comportamentais capturam hábitos e rotinas que podem impactar o desempenho acadêmico.

Study_Hours_per_Day registra a média de horas diárias dedicadas aos estudos. Assignment_Delay_Days mede o atraso médio na entrega de trabalhos, um indicador importante de engajamento. Travel_Time_Minutes captura o tempo de deslocamento diário até a instituição, fator que pode gerar desgaste e impactar a frequência.

O atributo Stress_Index representa o nível de estresse auto-relatado pelo estudante, em uma escala de 1 a 10. Níveis elevados de estresse estão frequentemente associados a problemas de saúde mental e risco de abandono.

2.4 VARIÁVEL ALVO

A variável Dropout é o atributo que desejamos prever. Trata-se de uma variável binária onde o valor 0 indica que o estudante permaneceu na instituição e o valor 1 indica que o estudante evadiu. Na base analisada, aproximadamente 76,5% dos estudantes permanecem (Dropout = 0) e 23,5% evadem (Dropout = 1).

3. PIPELINE DE TRATAMENTO DE DADOS

O pipeline de tratamento de dados é composto por três etapas fundamentais que preparam os dados brutos para utilização em algoritmos de Aprendizado de Máquina. Cada etapa aborda um tipo específico de problema comumente encontrado em datasets reais.

3.1 TRATAMENTO DE DADOS FALTANTES (MISSING VALUES)








3.1.1 O QUE SÃO DADOS FALTANTES?

Dados faltantes, também conhecidos como missing values, são valores ausentes em determinadas células do dataset. Eles podem ocorrer por diversos motivos: falhas na coleta de dados, recusa do respondente em fornecer determinada informação, erros de digitação ou problemas técnicos no armazenamento.

A presença de dados faltantes é problemática porque a maioria dos algoritmos de Machine Learning não consegue processar valores ausentes, resultando em erros de execução ou exclusão automática de registros importantes.

3.1.2 IDENTIFICAÇÃO DOS VALORES FALTANTES

Para identificar os valores faltantes, foi utilizado o nó Statistics do KNIME, que fornece um resumo estatístico completo de cada coluna, incluindo a contagem de valores ausentes.

Column	Min	Mean	Median	Max	Std. Dev.	Skewness	Kurtosis	No. Missing	No. +∞	No. -∞	Histogram
Student_ID	1	5.000,5	?	10.000	2.886,8957	0,0	-1,2	0	0	0	
Age	17	21,0261	?	29,6	2,1398	0,1832	-0,2827	0	0	0	
Family_Income	25.000	38.377,2475	?	316.601	20.496,2322	2,8269	13,889	500	0	0	
Study_Hours_per_Day	0,5	4,0146	?	8,98	1,2954	0,0315	-0,0136	500	0	0	
Attendance_Rate	38,2	81,7368	?	100	8,2209	-0,172	0,1326	0	0	0	
Assignment_Delay_Days	0,0	1,7997	?	8	1,3443	0,7044	0,3303	0	0	0	
Travel_Time_Minutes	5	30,1793	?	74,9	11,9189	0,0941	-0,2797	0	0	0	
Stress_Index	1	5,5071	?	10	1,766	-0,0077	-0,2452	500	0	0	

A análise identificou três colunas com valores ausentes:

Coluna	Tipo	Valores Faltantes	Proporção
Family_Income	Numérico	500	5%
Study_Hours_per_Day	Numérico	500	5%
Stress_Index	Numérico	500	5%

Observação sobre Parental_Education: A coluna Parental_Education contém o valor "None" em 511 registros. Ao importar o CSV no KNIME, este valor é automaticamente interpretado como dado faltante. Porém, "None" pode representar uma categoria válida indicando pais sem educação formal, não sendo necessariamente um dado ausente. Para fins deste trabalho, consideramos apenas as três colunas numéricas acima como dados faltantes.

3.1.3 ESTRATÉGIA DE TRATAMENTO

Foi definida a estratégia de imputação pela média para o tratamento dos dados faltantes. A imputação consiste em substituir os valores ausentes por valores estimados, permitindo manter todos os registros do dataset.

A justificativa para essa escolha baseia-se no fato de que a porcentagem de dados faltantes é relativamente baixa (5% em cada coluna afetada), o que permite realizar a substituição sem comprometer significativamente a distribuição original dos dados.

3.1.4 IMPLEMENTAÇÃO NO KNIME

O tratamento de dados faltantes foi implementado utilizando dois nós do KNIME Analytics Platform:

1. Nó Missing Value:

O nó Missing Value foi configurado para tratar as células vazias nas colunas numéricas:

Tipo de Dado	Tratamento Aplicado
Number (Integer)	Mean
Number (Float)	Mean

2. Nó String Replacer

Durante a importação do dataset, foi identificado que a coluna Parental_Education continha o valor "None" para indicar pais sem educação formal. Para padronizar e deixar mais claro o significado desse valor, foi utilizado o nó String Replacer com a seguinte configuração:

Coluna	Valor Original	Valor Substituído
Parental_Education	None	No_Education

Essa substituição garante que o valor seja interpretado corretamente como uma categoria válida ("sem educação formal") e não como um dado faltante.

3.1.5 RESULTADO

Após a aplicação do tratamento, todas as células vazias nas colunas numéricas foram preenchidas com a média, e os valores "None" em Parental_Education foram padronizados para

"No_Education". O dataset resultante possui zero valores faltantes, mantendo os 10.000 registros originais.

3.2.1 O QUE SÃO OUTLIERS?

Outliers, também conhecidos como valores atípicos ou discrepantes, são observações que se distanciam significativamente do padrão geral dos dados. Eles podem surgir por diversos motivos: erros de medição, falhas na coleta de dados, ou simplesmente representar casos genuinamente extremos dentro da população estudada.

A presença de outliers pode impactar negativamente algoritmos de Machine Learning, especialmente aqueles sensíveis à escala dos dados, como regressão linear e K-Nearest Neighbors (KNN). Por esse motivo, o tratamento de outliers é uma etapa importante no pré-processamento de dados.

3.2.2 MÉTODO DE DETECÇÃO: IQR (INTERQUARTILE RANGE)

Para identificação dos outliers, foi utilizado o método IQR (Interquartile Range), que é uma técnica estatística robusta baseada nos quartis da distribuição dos dados.

O método funciona da seguinte forma:

1. Calcula-se o primeiro quartil (Q1): valor abaixo do qual estão 25% dos dados
2. Calcula-se o terceiro quartil (Q3): valor abaixo do qual estão 75% dos dados
3. Calcula-se o IQR: $IQR = Q3 - Q1$
4. Definem-se os limites:
 - Limite inferior = $Q1 - 1,5 \times IQR$
 - Limite superior = $Q3 + 1,5 \times IQR$
5. Valores fora desses limites são considerados outliers

O fator $k = 1,5$ é o valor padrão recomendado na literatura estatística, sendo amplamente utilizado em análises exploratórias de dados.

3.2.3 COLUNAS ANALISADAS

O tratamento de outliers foi aplicado apenas às colunas numéricas que representam medidas contínuas. Foram excluídas da análise:

- Student_ID: identificador único, não representa uma medida
- GPA, Semester_GPA e CGPA: possuem escala fixa de 0 a 4, sem outliers por definição
- Dropout: variável alvo binária (0 ou 1)

3.2.4 OUTLIERS IDENTIFICADOS

A análise identificou outliers nas seguintes colunas:

Rows: 7 Columns: 5				Table  Statistics 			
☐	#	RowID	Outlier column (String)	Member count (Integer)	Outlier count (Integer)	Lower bound (Float)	Upper bound (Float)
☐	1	Row0	Age	10000	33	15	27
☐	2	Row1	Family_Income	10000	683	-2,547.875	70,913.125

Observação sobre limites negativos: O cálculo matemático do IQR pode gerar limites inferiores negativos para algumas variáveis (como renda ou tempo). Porém, como o dataset não contém outliers inferiores nessas colunas (todos os valores estão acima do limite inferior calculado), nenhum valor foi substituído por números negativos na prática.

3.2.5 ESTRATÉGIA DE TRATAMENTO: WINSORIZAÇÃO

Para o tratamento dos outliers identificados, foi aplicada a técnica de winsorização, que consiste em substituir os valores extremos pelo limite mais próximo permitido.

Existem diferentes abordagens para tratar outliers:

Abordagem	Descrição	Vantagem	Desvantagem
Remoção de linhas	Excluir registros com outliers	Simples	Perda de Dados
Substituição por missing	Trocar outliers por valores vazios		Cria novos missing values
Winsorização	Substituir pelo limite mais próximo	Preserva dados e informações	

A winsorização foi escolhida por preservar o tamanho da amostra (10.000 registros) e manter a informação de que o valor é extremo, substituindo-o pelo limite máximo ou mínimo permitido.

3.2.6 IMPLEMENTAÇÃO NO KNIME

O tratamento foi implementado utilizando o nó Numeric Outliers do KNIME Analytics Platform, com a seguinte configuração:

Parâmetro	Valor
Método	IQR (Interquartile Range)
Fator k	1,5
Estimation type	R6
Quartile calculation	Full data estimate
Treatment option	Replace outlier values

Replacement strategy	Closest permitted value
----------------------	-------------------------

3.2.7 RESULTADO

Após a aplicação do tratamento, os 1.098 valores identificados como outliers foram substituídos pelos limites mais próximos permitidos. O dataset manteve todos os 10.000 registros originais, agora com valores dentro dos limites aceitáveis definidos pelo método IQR.

3.3 REDUÇÃO DE DIMENSIONALIDADE

3.3.1 O QUE É REDUÇÃO DE DIMENSIONALIDADE?

Redução de dimensionalidade é uma técnica que diminui o número de variáveis (features) de um dataset, mantendo a maior quantidade possível de informação relevante. Essa etapa é importante porque datasets com muitas variáveis podem causar problemas como overfitting, alto custo computacional e dificuldade de visualização. Além disso, variáveis correlacionadas entre si (como GPA, Semester_GPA e CGPA) podem representar informações redundantes que não contribuem para o aprendizado do modelo.

3.3.2 TÉCNICA UTILIZADA: PCA (PRINCIPAL COMPONENT ANALYSIS)

Foi aplicada a técnica PCA (Análise de Componentes Principais), que transforma as variáveis originais em um novo conjunto de variáveis chamadas componentes principais. Esses componentes são combinações lineares das variáveis originais, ordenados de forma que os primeiros capturam a maior parte da variância dos dados.

O PCA foi configurado para reduzir o dataset a 5 componentes principais.

3.3.3 PRÉ-PROCESSAMENTO NECESSÁRIO

Antes de aplicar o PCA, foram necessárias duas etapas de preparação:

1. Etapa: Conversão de categóricas

- **Nó KNIME:** Category to Number
- **Descrição:** O PCA opera apenas com dados numéricos. As variáveis categóricas (Gender, Internet_Access, Part_Time_Job, Scholarship, Semester, Department e Parental_Education) foram convertidas para valores inteiros.

2. Etapa: Normalização

- **Nó KNIME:** Normalizer (Z-score)
- **Descrição:** O PCA é sensível à escala das variáveis. A normalização Z-score transforma os dados para média 0 e desvio padrão 1, garantindo que todas as variáveis contribuam igualmente.

3.3.4 COLUNAS ANALISADAS

Foram incluídas no PCA 17 variáveis numéricas (após a conversão das categóricas).

Colunas excluídas do PCA:

Coluna	Motivo da Exclusão
Student_ID	Identificador único, sem valor preditivo
Dropout	Variável alvo (target), não deve participar da transformação

3.3.5 IMPLEMENTAÇÃO NO KNIME

A redução de dimensionalidade foi implementada utilizando três nós em sequência:

Nó	Configuração
Category to Number	Colunas: todas as categóricas; Start value: 0; Increment: 1
Normalizer	Método: Z-score; Excluídas: Student_ID, Dropout
PCA	Dimensões: 5; Excluídas: Student_ID, Dropout; Remove original columns: Sim

3.3.6 RESULTADO

Métrica	Valor
Variáveis antes da redução	17
Variáveis após a redução	5 componentes principais
Taxa de redução	70,6%
Registros mantidos	10.000 (todos)

Após a aplicação do PCA, o dataset final contém 7 colunas: Student_ID (identificador), Dropout (variável alvo) e os 5 componentes principais (PCA dimension 0 a 4). Os valores dos componentes variam aproximadamente entre -4 e +4, resultado esperado da normalização Z-score. O dataset está agora otimizado para algoritmos de aprendizado de máquina, com dimensionalidade reduzida e sem informações redundantes.

4. IMPLEMENTAÇÃO NO KNIME

4.1 VISÃO GERAL DO PIPELINE

O pipeline de tratamento de dados foi implementado na ferramenta KNIME Analytics Platform, uma plataforma visual de código aberto para análise de dados. O workflow completo é composto por 8 nós conectados sequencialmente, organizados da seguinte forma:

Ordem	Nó	Função
1	CSV Reader	Importação do dataset original
2	Statistics	Análise exploratória inicial
3	Missing Value	Tratamento de valores faltantes (média)
4	String Replacer	Padronização de "None" para "No_Education"
5	Numeric Outliers	Detecção e tratamento de outliers (IQR + Winsorização)
6	Category to Number	Conversão de variáveis categóricas para numéricas
7	Normalizer	Normalização Z-score
8	PCA	Redução de dimensionalidade (5 componentes)


4.2 FLUXO DE DADOS

O fluxo de dados segue uma ordem lógica onde cada etapa depende da anterior:

- Entrada:** Dataset bruto com 10.000 registros e 19 atributos
- Limpeza:** Tratamento de 1.500 valores faltantes e 1.098 outliers
- Transformação:** Conversão de 7 variáveis categóricas e normalização
- Redução:** Compressão de 17 features para 5 componentes principais
- Saída:** Dataset processado com 10.000 registros e 7 colunas (Student_ID + Dropout + 5 PCAs)

4.3 WORKFLOW FINAL

O workflow abaixo representa o pipeline completo de pré-processamento. Todos os nós apresentam status verde, indicando execução bem-sucedida sem erros



5. CONCLUSÃO

O pipeline desenvolvido demonstrou-se eficaz na preparação dos dados para uso em algoritmos de aprendizado de máquina. As principais contribuições deste trabalho foram:

1. **Preservação dos dados:** Todas as 10.000 observações foram mantidas, evitando perda de informação através do uso de técnicas de imputação e winsorização em vez de remoção de registros.
2. **Qualidade dos dados:** O dataset resultante não possui valores faltantes nem outliers que possam distorcer o treinamento de modelos preditivos.
3. **Eficiência computacional:** A redução de 17 para 5 variáveis diminui significativamente o custo computacional e o risco de overfitting em etapas posteriores de modelagem.
4. **Reprodutibilidade:** O uso do KNIME permite que o pipeline seja facilmente replicado, modificado e aplicado a outros datasets com características semelhantes.

O dataset final, contendo os 5 componentes principais gerados pelo PCA juntamente com a variável alvo (Dropout), está pronto para ser utilizado em algoritmos de classificação como Random Forest, SVM ou Redes Neurais, com o objetivo de prever a evasão estudantil e permitir intervenções preventivas por parte das instituições de ensino.