

**INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE MINAS
GERAIS – CAMPUS FORMIGA**

INTELIGÊNCIA ARTIFICIAL

FLÁVIO ALEXANDRE SILVA REIS

LUISA CAETANO ARAÚJO

MARIA LUZIA DE MOURA SANCHES

YASMIN STEFANE FARIA

**COMPARAÇÃO DE PIPELINES DE APRENDIZAGEM DE MÁQUINA
NO KNIME**

PREVISÃO DE EVASÃO ESTUDANTIL

FORMIGA

2026

1. INTRODUÇÃO

A qualidade dos dados é um fator determinante para o sucesso de projetos de Aprendizado de Máquina. Dados brutos frequentemente apresentam inconsistências, valores ausentes e anomalias que podem comprometer o desempenho dos modelos preditivos. No entanto, surge a questão: o pré-processamento sempre melhora os resultados?

O presente trabalho tem como objetivo comparar o desempenho de dois pipelines de classificação no KNIME: um utilizando dados brutos e outro com tratamento completo de dados (valores faltantes, outliers e redução de dimensionalidade via PCA). O classificador escolhido foi o Random Forest, aplicado à tarefa de prever a evasão estudantil.

2. BASE DE DADOS

A base de dados utilizada neste trabalho foi obtida no repositório Kaggle, uma das maiores plataformas de compartilhamento de datasets para ciência de dados e aprendizado de máquina.

O Student Dropout Prediction Dataset contém registros de 10.000 estudantes universitários, caracterizados por 19 atributos distintos. A base foi projetada para simular cenários reais de instituições de ensino superior, incorporando características como valores faltantes em aproximadamente 5% dos registros e a presença de outliers em variáveis como renda familiar.

Item	Descrição
Nome	Student Dropout Prediction Dataset
Fonte	Kaggle
Link	https://www.kaggle.com/datasets/meharshanali/student-dropout-prediction-dataset
Número de Registros	10.000
Número de Atributos	19


A variável Dropout é o atributo que desejamos prever. Trata-se de uma variável binária onde:

- 0: estudante permaneceu na instituição (76,5%)
- 1: estudante evadiu (23,5%)

3. PIPELINE A - SEM TRATAMENTO DE DADOS

O primeiro pipeline utiliza os dados em sua forma bruta, sem nenhuma etapa de pré-processamento. O objetivo é estabelecer uma linha de base (baseline) para comparação.

3.1 ESTRUTURA DO PIPELINE



3.2 DESCRIÇÃO DOS NÓS

Nome	Descrição
CSV Reader	Importa o dataset original com todos os 10.000 registros e 19 atributos
Number to String	Converte a variável alvo (Dropout) de numérica para categórica, conforme exigido pelo classificador
Table Partitioner	Divide os dados em 70% para treino e 30% para teste
Random Forest Learner	Treina o modelo com as 18 variáveis preditoras originais
Random Forest Predictor	Aplica o modelo treinado nos dados de teste
Scorer	Calcula as métricas de desempenho (acurácia, precisão, recall, F1-score)

3.3 OBSERVAÇÕES


Neste pipeline:

- Não foi aplicada substituição de valores faltantes
- Não foi aplicado tratamento de outliers
- Não foi aplicada redução de dimensionalidade
- O Random Forest lida internamente com os valores faltantes

4. PIPELINE B - COM TRATAMENTO DE DADOS

O segundo pipeline aplica técnicas de pré-processamento antes do treinamento do modelo, incluindo tratamento de dados faltantes, outliers e redução de dimensionalidade.

4.1 ESTRUTURA DO PIPELINE



4.2 DESCRIÇÃO DOS NÓS

Nome	Descrição
CSV Reader	Importa o dataset original com todos os 10.000 registros e 19 atributos
Missing Value	Preenche células vazias com a média da coluna (variáveis numéricas)
String Replacer	Padroniza valores de texto inconsistentes (ex: "None" → "No_Education")
Numeric Outliers	Detecta e trata valores extremos usando o método IQR com winsorização
Category to Number	Converte variáveis categóricas para valores numéricos inteiros
Normalizer	Aplica normalização Z-score (média 0, desvio padrão 1)
PCA	Reduz a dimensionalidade para 5 componentes principais
Number to String	Converte a variável alvo (Dropout) de volta para texto categórico
Table Partitioner	Divide os dados em 70% treino e 30% teste
Random Forest Learner	Treina o modelo com os 5 componentes do PCA
Random Forest Predictor	Aplica o modelo treinado nos dados de teste
Scorer	Calcula as métricas de desempenho (acurácia, precisão, recall, F1-score)

4.3 DESCRIÇÃO DOS TRATAMENTOS REALIZADOS

4.3.1 TRATAMENTO DE DADOS FALTANTES

Foram identificados 1.500 valores faltantes (5% do total) distribuídos em três colunas:

Coluna	Tipo	Valores Faltantes	Proporção
Family_Income	Numérico	500	5%
Study_Hours_per_Day	Numérico	500	5%
Stress_Index	Numérico	500	5%

Estratégia aplicada: Imputação pela média, substituindo os valores ausentes pela média da respectiva coluna.

Justificativa: A porcentagem de dados faltantes é relativamente baixa, permitindo a substituição sem comprometer a distribuição original.

4.3.2 TRATAMENTO DE OUTLIERS

Foram identificados 1.098 outliers utilizando o método IQR (Interquartile Range):

Coluna	Outliers Encontrados
Family_Income	683
Study_Hours_per_Day	138
Stress_Index	137
Attendance_Rate	57
Age	33
Assignment_Delay_Days	25
Travel_Time_Minutes	25

Estratégia aplicada: Winsorização — substituição dos valores extremos pelo limite mais próximo permitido ($Q1 - 1,5 \times IQR$ ou $Q3 + 1,5 \times IQR$).

Justificativa: Preserva todos os 10.000 registros, evitando perda de informação.


4.3.3 REDUÇÃO DA DIMENSIONALIDADE

Foi aplicada a técnica PCA (Principal Component Analysis) para reduzir o número de variáveis:

Métrica	Valor
Variáveis antes da redução	17

Variáveis após a redução	5 componentes principais
Taxa de redução	70,6%

5. CLASSIFICADOR UTILIZADO



5.1 RANDOM FOREST

O classificador escolhido para ambos os pipelines foi o Random Forest (Floresta Aleatória), um algoritmo de aprendizado de máquina do tipo ensemble, baseado na construção de múltiplas árvores de decisão.

5.2 FUNCIONAMENTO

O Random Forest opera da seguinte forma:

1. **Bootstrap Sampling:** Cria múltiplas amostras aleatórias (com reposição) dos dados de treino
2. **Construção de árvores:** Treina uma árvore de decisão para cada amostra
3. **Feature Randomness:** Em cada divisão, considera apenas um subconjunto aleatório de atributos
4. **Votação majoritária:** A predição final é a classe mais votada entre todas as árvores

5.3 JUSTIFICATIVA DA ESCOLHA

Característica	Benefício
Robusto a overfitting	O ensemble de árvores reduz a variância do modelo

Tolerante a outliers	Menos sensível a valores extremos
Não requer normalização	Funciona bem com dados em diferentes escalas
Lida com missing values	Tratamento interno de valores ausentes
Importância de variáveis	Permite identificar atributos mais relevantes

6. COMPARAÇÃO DOS RESULTADOS


6.1 TABELA COMPARATIVA

Com base nos experimentos realizados, foram obtidos os seguintes resultados:


Métrica	Pipeline SEM Tratamento	Pipeline COM Tratamento
Acurácia	79,7%	78,2%
Recall (classe 0 - Permaneceu)	83,1%	83,2%
Recall (classe 1 - Evadiu)	60,7%	55,2%
Precisão (classe 0 - Permaneceu)	92,2%	89,7%
Precisão (classe 1 - Evadiu)	39,1%	41,2%
F1-score (classe 0 - Permaneceu)	87,4%	86,3%
F1-score (classe 1 - Evadiu)	47,6%	47,2%

6.2 VISUALIZAÇÃO GRÁFICA

O gráfico de barras abaixo permite visualizar a comparação direta entre os dois pipelines para cada métrica avaliada:



6.3 ANÁLISE PRECISION VS RECALL



Interpretação do gráfico:

- **Pontos no canto superior direito (alta precisão e alto recall):** Representam a classe 0 (Permaneceu) em ambos os pipelines — o modelo tem bom desempenho para identificar estudantes que permanecem.
- **Pontos no canto inferior esquerdo (baixa precisão e recall moderado):** Representam a classe 1 (Evadiu) — o modelo tem mais dificuldade em identificar corretamente os estudantes que evadem, com muitos falsos positivos.

7. ANÁLISE DOS RESULTADOS

Os resultados obtidos revelam um cenário contraintuitivo: o pipeline sem tratamento de dados apresentou desempenho ligeiramente superior ao pipeline com tratamento completo.

Principais Interpretações:

1. **Acurácia geral:** O pipeline sem tratamento alcançou 79,7%, contra 78,2% do pipeline com tratamento — uma diferença de 1,5 pontos percentuais.
2. **Deteção de evasão (classe 1):** O recall para a classe minoritária foi de 60,7% sem tratamento versus 55,2% com tratamento. Isso significa que o modelo sem tratamento identificou corretamente mais estudantes em risco de evasão.
3. **Precisão para a classe majoritária (classe 0):** O pipeline sem tratamento obteve 92,2% de precisão, indicando menos falsos positivos.

7.1 POR QUE O TRATAMENTO NÃO MELHOROU O DESEMPENHO?

1. Características do Random Forest

O algoritmo Random Forest é naturalmente robusto a valores faltantes, outliers e alta dimensionalidade. As etapas de tratamento que seriam essenciais para outros algoritmos (como SVM ou Regressão Logística) podem ser redundantes para o Random Forest.

2. Perda de informação no PCA

A redução de 17 variáveis para 5 componentes principais, embora capture a maior parte da variância estatística, pode ter descartado padrões discriminativos importantes para a classificação. Variáveis que individualmente tinham baixa variância podem ser altamente preditivas para identificar evasão.

3. Qualidade original dos dados

O dataset possui apenas 5% de valores faltantes e outliers controlados. Em bases de dados reais com maior degradação de qualidade, o tratamento provavelmente teria impacto mais significativo.

8. CONCLUSÃO

O tratamento dos dados contribuiu para melhorar o desempenho do classificador?

Não. Os resultados mostram que o pipeline sem tratamento obteve acurácia de 79,7%, enquanto o pipeline com tratamento alcançou 78,2% — uma diferença de 1,5 pontos percentuais a favor dos dados brutos. Além disso, o recall para detecção de evasão (classe 1) foi maior sem tratamento (60,7% vs 55,2%), indicando que mais estudantes em risco foram corretamente identificados.

Isso ocorre porque o Random Forest é naturalmente robusto a valores faltantes e outliers, e a redução de dimensionalidade via PCA pode ter descartado informações relevantes para a classificação.